

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Facultad de Ciencias Matemáticas
Escuela Profesional de Estadística

DOCUMENTO DE ARQUITECTURA
Sistema Big Data para el pronóstico y la alerta temprana
de precios de alimentos en el Perú

Food Price Forecasting Peru

Curso	Big Data Analytics
Docente	Víctor Guevara Ponce
Integrantes	Alexis Medrano Rivera Daniel Quispe Villena Andrew Rivera Laura Carlos Luis Estefano Garrido Silva
Periodo académico	2026-I
Fecha	10 de julio de 2026

1. Propósito y alcance

El proyecto propone una arquitectura Big Data para integrar precios mayoristas de alimentos, variables climáticas de las zonas productoras y publicaciones de Twitter/X. El sistema transforma estas fuentes en un Data Lake con arquitectura Medallion, entrena modelos predictivos y de segmentación, registra los experimentos con MLflow y entrega indicadores mediante un dashboard en Streamlit.

El documento describe el flujo completo del sistema, las fuentes con sus formatos y volúmenes, las capas Bronce, Plata y Oro, los componentes de procesamiento y analítica, y el plan de trabajo por semana. Se diferencia entre los componentes ya evidenciados en el repositorio y aquellos que aún están planificados o en desarrollo.

1.1 Problema que atiende el sistema

La volatilidad de los precios de alimentos básicos afecta de forma directa el presupuesto de los hogares y dificulta la respuesta oportuna de las instituciones. Los cambios de precio pueden estar asociados al comportamiento histórico del mercado, las condiciones climáticas en las zonas productoras y la percepción pública expresada en redes sociales. El sistema busca integrar estas señales para anticipar alzas y priorizar productos que requieren monitoreo frecuente.

Pregunta central

¿Cuál será el precio mayorista de un alimento en Lima dentro de dos semanas y qué productos presentan un perfil de mayor riesgo o volatilidad que justifique una alerta temprana?

1.2 Objetivo general

Diseñar e implementar un sistema Big Data escalable que integre información de precios, clima y texto libre para pronosticar precios de alimentos a dos semanas, identificar perfiles de volatilidad y generar indicadores listos para el consumo de un dashboard ejecutivo.


1.3 Usuarios y decisiones

- MIDAGRI y gestores públicos: priorización de productos y periodos de vigilancia.
- Administradores de mercados: seguimiento de variaciones y anticipación de posibles alzas.
- Analistas y periodistas: consulta de series, factores climáticos y percepción social.
- Ciudadanía: acceso a información comprensible sobre tendencias y alertas de precios.

1.4 Requisitos de arquitectura

Dimensión	Requisito del sistema
Datos	Integrar tres tipos de dato: series de precios, series climáticas/sensores y texto libre.
Almacenamiento	Google Cloud Storage como Data Lake con zonas Bronce, Plata y Oro.
Procesamiento	Apache Spark/PySpark como motor central; Spark SQL para agregaciones y KPIs.
Analítica	Modelos de forecasting, clustering y clasificación de alertas; seguimiento en MLflow.
Consumo	Dashboard Streamlit con 5 o más vistas, incluida una vista de salud del sistema.
Actualización	Batch para SISAP/SENAMHI y streaming planificado con GCP Pub/Sub para tweets.

2. Diagrama completo del sistema



GCS: Google Cloud Storage | Flujo principal: fuentes → ingesta → Bronce → Plata → analítica/Oro → dashboard

Figura 1. Arquitectura de extremo a extremo. Las líneas discontinuas indican componentes planificados o pendientes de integración.

3. Fuentes de datos

El inventario se construyó a partir del repositorio del proyecto y de las fuentes oficiales indicadas en la guía del curso. Los volúmenes corresponden a la ejecución registrada en los notebooks; cuando el tamaño físico no está disponible, se reporta el número de archivos o registros como medida de volumen.

Fuente	Contenido	Formato / tipo	Frecuencia	Volumen observado	URL
SISAP - MIDAGRI	Precios mayoristas de alimentos en mercados de Lima	XLS; datos estructurados y serie temporal	Histórico cargado por lote; fuente de actualización diaria	10 archivos; 35,994 registros crudos; 34,969 registros mapeados; 10 productos	sisistemas.midagri.gob.pe/sisap
SENAMHI	Temperatura máxima/mínima, humedad y precipitación de zonas productoras	CSV; serie temporal climática / sensor	Datos diarios; agregación semanal en el pipeline	7 archivos/estaciones; 18,841 observaciones; 548.5 KiB descargados; periodo 2015-2024	senamhi.gob.pe - descarga de datos
Twitter / X	Publicaciones sobre precios y alimentos en Lima, con likes, retweets y término de búsqueda	JSON; texto libre + metadatos	Histórico en batch; objetivo de streaming casi real	5,133 registros crudos; 5,132 limpios; 465 semanas; 2015-01-10 a 2024-06-26	developer.twitter.com

3.1 Criterios de calidad y transformación inicial

Fuente	Tratamiento principal	Observación de calidad
SISAP	Lectura robusta de tablas XLS, estandarización de fecha y precio, detección de producto, mapeo a mercado, distrito, ubigeo y región climática.	1,025 registros no quedaron en el conjunto mapeado respecto al volumen crudo; deben documentarse como descartados o no reconocidos.
SENAMHI	Normalización de nombres de columnas, conversión de S/D, SD y T a nulos, creación de temperatura promedio y banderas de helada/lluvia intensa.	Parte del histórico no empata con todos los productos; el join reporta 2,345 registros con clima completo de 5,225 semanales.
Twitter / X	Eliminación de duplicados por ID, limpieza de URL, mención, hashtag y puntuación; imputación de likes/retweets; análisis BERT.	5,132 registros válidos. Distribución: 43.6% negativo, 47.9% neutro y 8.5% positivo.

4. Flujo de datos y arquitectura Medallion

4.1 Ingesta y transporte

La ingesta histórica actual es de tipo batch. Los archivos SISAP y SENAMHI son descargados o cargados al bucket y los tweets se almacenan como un archivo JSON. Para cumplir el objetivo de una vista en tiempo casi real, la arquitectura incorpora GCP Pub/Sub como componente planificado para recibir nuevas publicaciones y escribirlas en micro-lotes en la Zona Bronce.

4.2 Zona Bronce

Conjunto	Ruta GCS	Formato	Regla de la capa
SISAP	gs://food-price-peru-2025-01/bronze/sisap/	XLS	Datos originales sin modificar.
SENAMHI	gs://food-price-peru-2025-01/bronze/senamhi/	CSV	Archivos diarios por estación o zona productora.
Tweets	gs://food-price-peru-2025-01/bronze/tweets/bronze_tweets_precios_lima.json	JSON	Texto y metadatos tal como fueron recolectados.

4.3 Procesamiento Bronce → Plata

1. SISAP: lectura de archivos, normalización, mapeo del producto a mercado, distrito, ubigeo y región climática, y agregación semanal.
2. SENAMHI: limpieza de variables meteorológicas, cálculo de temperatura promedio, heladas y lluvia intensa, y agregación por región y semana.
3. Integración: join por región climática, año y semana; posterior generación de lags de precio, medias móviles, variación, estacionalidad y target a dos semanas.
4. Tweets: limpieza de texto y clasificación de sentimiento con BERT en español; agregación semanal de volumen, sentimiento promedio y porcentajes negativos/positivos.
5. Persistencia: formatos Parquet particionados para mejorar lectura analítica y trazabilidad.

4.4 Zona Plata

Dataset	Ruta relativa en el bucket	Formato	Volumen / propósito
precios_sisap_limpios	/plata/precios_clima_integrado/precios_sisap_limpios.csv	CSV	34,969 registros mapeados
precios_spark	/plata/precios_clima_integrado/precios_spark	Parquet	Precios procesados y particionados
precios_clima_parquet	/plata/precios_clima_integrado/precios_clima_parquet	Parquet	5,225 filas semanales; 10 productos
matriz_aprendizaje_forecasting	/plata/precios_clima_integrado/matriz_aprendizaje_forecasting	Parquet	4,697 filas con lags y targets
tweets_sentimiento	/plata/tweets_sentimiento	Parquet	5,132 tweets procesados
tweets_sentimiento_semanal	/plata/tweets_sentimiento_semanal	Parquet	465 semanas agregadas

5. Analítica avanzada y MLflow

5.1 Modelo 1: forecasting de precios a dos semanas

La matriz de aprendizaje integra precios, clima y sentimiento. Después de excluir productos no agrícolas y eliminar filas sin target, el conjunto final contiene 2,808 observaciones de seis productos agrícolas. El split temporal utiliza 1,884 filas para 2017-2022 y 924 filas para 2023-2025. Se seleccionan 19 variables mediante filtros de colinealidad y significancia, conservando además variables de estacionalidad.

Modelo	RMSE S//kg	MAE S//kg	R ²	Resultado
Regresión lineal	1.0169	0.3472	0.8591	Ganador por menor RMSE
XGBoost	1.2363	0.3962	0.7918	Modelo no lineal comparativo
Random Forest	1.2471	0.3982	0.7881	Modelo de ensamble comparativo

Resultado registrado

El modelo ganador es la regresión lineal. El artefacto modelo1_forecasting.pkl y la lista de variables se guardan en gs://food-price-peru-2025-01/oro/modelos/. Los experimentos y métricas se conservan en MLflow.

5.2 Modelo 2: clustering de productos

El segundo módulo resume cada producto mediante precio promedio histórico, volatilidad, máximo, mínimo y exposición a lluvia. Compara KMeans y clustering aglomerativo para K=2, 3 y 4; la selección se realiza con Silhouette Score. El notebook está preparado para escribir una tabla de 10 productos en la Zona Oro, junto con el nombre del modelo y su métrica.

5.3 Modelo 3 propuesto: clasificación de alertas

La matriz de Plata ya contiene la variable `target_alerta_10`, que identifica una variación futura igual o superior a 10%. Se propone comparar regresión logística, Random Forest/GBT Classifier y XGBoost Classifier, utilizando métricas F1, recall de la clase alerta y AUC-ROC. Este componente se presenta como parte de la arquitectura objetivo y permanece pendiente de implementación.

5.4 Gestión de experimentos con MLflow

- Registrar algoritmo, hiperparámetros, versión del dataset y fecha de ejecución.
- Guardar RMSE, MAE y R^2 para regresión; Silhouette e inercia para clustering; F1, recall y AUC para clasificación.
- Persistir artefactos: modelos serializados, lista de features, gráficos y tablas comparativas.
- Promover únicamente el modelo validado hacia la Zona Oro y el dashboard.

6. Zona Oro y consumo

La Zona Oro contiene salidas agregadas y modeladas listas para consulta directa. Al momento de revisar el repositorio, el modelo de forecasting ya escribe artefactos en Oro y el notebook de clustering contiene la instrucción de persistencia. Las tablas KPI están en construcción por el equipo; por ello se documentan como diseño objetivo y deben validarse al finalizar su ejecución.

Objeto Oro	Contenido principal	Formato	Consumo	Estado
kpi_precios	Precio promedio semanal, precio anterior, variación porcentual, nivel NORMAL/ATENCIÓN/ALE RTA y fecha de carga.	Parquet	Vista 1: variación y alertas	En desarrollo
prediccionesPrecio	Producto, semana objetivo, precio estimado, intervalo/indicador de confianza y versión del modelo.	Parquet	Vista 2: pronóstico a 2 semanas	Planificado
clusters_productos	Producto, cluster, precio histórico, volatilidad, máximos/mínimos, exposición a lluvia, modelo y Silhouette.	Parquet	Vista 3: segmentación	Escritura programada en notebook
drivers_producto	Variables climáticas y de precio relevantes por producto y semana.	Parquet	Vista 4: clima y factores	Planificado
kpi_sentimiento	Sentimiento promedio semanal, número de tweets, porcentajes negativos/positivos y retweets.	Parquet	Vista 5: sentimiento	En desarrollo
estado_pipeline	Última ejecución, fuente, conteo, estado, errores y versión del modelo.	Parquet/JSON	Vista 6: salud del sistema	Planificado
modelos/	Modelo ganador de forecasting, features y futuros modelos aprobados.	PKL/TXT	Consumo del backend	Implementado para Modelo 1

6.1 Vistas del dashboard

Vista	Pregunta que responde	Dataset	Elementos
1	¿Qué productos presentan variaciones que requieren atención?	kpi_precios	KPIs, ranking y semáforo de alertas.
2	¿Cuál será el precio de cada producto dentro de dos semanas?	prediccionesPrecio + modelo	Serie histórica, predicción y error esperado.

Vista	Pregunta que responde	Dataset	Elementos
3	¿Qué productos comparten un perfil de riesgo y volatilidad?	clusters_productos	Scatter de precio vs. volatilidad y detalle por cluster.
4	¿Qué variables climáticas y temporales explican el comportamiento?	Plata + drivers_producto	Tendencias de clima, precio y factores.
5	¿Cómo evoluciona la percepción social sobre los precios?	kpi_sentimiento	Sentimiento, volumen de tweets y negatividad.
6	¿Está actualizado y saludable el sistema?	estado_pipeline	Frescura, fuentes activas, conteos y versión del modelo.

7. Linaje, seguridad y operación

Dominio	Origen	Bronce	Plata	Oro / consumo
Precios	SISAP XLS	bronze/sisap	precios_spark → precios_clima_parquet → matriz_forecasting	kpi_precios, predicciones y modelos
Clima	SENAMHI CSV	bronze/senamhi	clima_completo → join semanal → features climáticas	drivers, predicciones y clustering
Texto	Tweets JSON	bronze/tweets	tweets_sentimiento → sentimiento_semanal	kpi_sentimiento y features del forecast

7.1 Consideraciones no funcionales

- Reproducibilidad: notebooks versionados en GitHub y parámetros registrados en MLflow.
- Escalabilidad: almacenamiento columnar Parquet y procesamiento Spark; particionamiento por año y producto.
- Trazabilidad: conservar archivo de origen, fecha de carga, conteos de entrada/salida y versión de modelo.
- Seguridad: acceso al bucket mediante identidades de servicio, principio de mínimo privilegio y exclusión de credenciales del repositorio.
- Calidad: pruebas de esquema, unicidad, nulos, rangos de precio/clima y consistencia de fechas antes de promover datos a Plata/Oro.
- Disponibilidad: dashboard desacoplado de los notebooks y lectura exclusiva de datasets Oro para evitar cálculos pesados en línea.

8. Plan de trabajo por semana

Sem.	Fase	Actividades principales	Entregable	Estado
8	Comprensión del problema y propuesta	Definir pregunta central, stakeholders, preguntas analíticas y fuentes confirmadas.	Propuesta de proyecto	Completado
9	Arquitectura	Diseñar flujo completo, fuentes, Medallion, componentes analíticos y plan semanal.	Documento de arquitectura + diagrama	En elaboración
10	Ingesta y Zona Bronce	Consolidar cargas SISAP, SENAMHI y tweets; documentar esquemas y conteos.	Bronce poblada + control de ingesta	Avanzado
11	ETL y Zona Plata	Ejecutar limpieza, join semanal, feature engineering y persistencia Parquet.	Pipeline Bronce → Plata reproducible	Completado
12	NLP y streaming	Procesar sentimiento; diseñar/activar Pub/Sub para nuevas publicaciones.	Parquet NLP + demo de ingesta	NLP completado; streaming pendiente

Sem.	Fase	Actividades principales	Entregable	Estado
13	Modelo 1 y MLflow	Entrenar y comparar regresión lineal, RF y XGBoost; registrar experimentos.	Forecasting evaluado + MLflow	Completado
14	Modelos 2 y 3 + Oro	Ejecutar clustering, construir clasificador de alertas y generar tablas Oro.	3 modelos + Data Lake completo	En curso
15	Dashboard	Construir seis vistas, conectar a Oro, incorporar vista en tiempo casi real y salud.	Dashboard Streamlit funcional	Pendiente
16	Evaluación y despliegue	Pruebas integrales, validación de preguntas, reporte, presentación y video.	Reporte final + demo	Pendiente

8.1 Dependencias críticas

- La Zona Oro debe estar poblada y validada antes de conectar el dashboard.
- El dashboard requiere nombres de columnas y rutas estables; cualquier cambio debe versionarse.
- La vista casi real depende de implementar Pub/Sub y una escritura incremental segura.
- El tercer modelo y su tabla de scores son necesarios para cumplir el mínimo de tres modelos del proyecto final.

9. Estado actual y brechas

Componente	Situación observada	Acción pendiente
Repositorio y estructura	Carpetas de Data Lake, notebooks y MLflow presentes.	Mantener README con instrucciones ejecutables.
Zona Bronce	Rutas y archivos evidenciados por las ejecuciones de los notebooks.	Agregar scripts de recolección al repositorio; las carpetas scripts/src están vacías en el snapshot.
Zona Plata	Precios/clima y NLP procesados en Parquet.	Formalizar pruebas automáticas de calidad y esquema.
Modelo 1	Tres algoritmos comparados y registrados; artefacto ganador en Oro.	Publicar versión del dataset y asegurar compatibilidad del modelo con dashboard.
Modelo 2	Código completo y escritura a Oro programada.	Configurar PROJECT_ID real y validar ejecución/filas.
Modelo 3	Target disponible en la matriz.	Implementar, comparar y registrar en MLflow.
Zona Oro	Diseño definido; KPIs y clustering en desarrollo.	Confirmar rutas, columnas, conteos y fecha de carga.
Streaming	Incluido en la arquitectura objetivo.	Implementar Pub/Sub y demostrar actualización casi real.
Dashboard	Carpeta creada, sin código en el snapshot revisado.	Desarrollar 6 vistas y conectar exclusivamente a Oro.

Conclusión de arquitectura

La arquitectura es coherente con el problema y con los requisitos del curso: integra tres tipos de dato, usa GCS y Medallion, procesa con Spark y registra modelos en MLflow. Para cerrar la arquitectura funcional quedan cuatro frentes prioritarios: completar la Zona Oro, implementar el tercer modelo, activar la ingesta streaming y desarrollar el dashboard.

10. Referencias y artefactos revisados

- Repositorio del proyecto: <https://github.com/AlKstudent/food-price-forecasting-peru>
- MIDAGRI - SISAP: <https://sistemas.midagri.gob.pe/sisap>
- SENAMHI - descarga de datos hidrometeorológicos: <https://www.senamhi.gob.pe/?p=descarga-datos-hidrometeorologicos>
- Twitter/X Developer Platform: <https://developer.twitter.com>
- Apache Spark: <https://spark.apache.org>
- MLflow: <https://mlflow.org>
- Streamlit: <https://streamlit.io>

Anexo A. Archivos técnicos revisados

- README.md
- 01_EDA_Exploratorio.ipynb
- 02_ETL_Bronce_a_Plata.ipynb
- 03_NLP_tweets_sentimiento.ipynb
- 04_Modelo_1_Forecasting.ipynb
- 05_modelo2_clustering.ipynb
- docs/mlruns/mlruns_modelo1.zip
- docs/mlruns/mlruns_modelo2.zip
- ProyectoFinal_BigData2.pdf

Fin del documento