

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Universidad del Perú. Decana de América

FACULTAD DE CIENCIAS MATEMÁTICAS

ESCUELA PROFESIONAL DE ESTADÍSTICA



Sistema Big Data para el pronóstico y la alerta temprana de precios de alimentos en el Perú

Documento de Arquitectura

INTEGRANTES DEL GRUPO 5:

MEDRANO RIVERA, ALEXIS

QUISPE VILLENA, DANIEL

RIVERA LAURA, ANDREW

GARRIDO SILVA, CARLOS LUIS ESTEFANO

ASIGNATURA:

Big Data

DOCENTE:

GUEVARA PONCE, VÍCTOR

2026 – I

Lima, Perú

Índice

1. Propósito y alcance	1
1.1. Objetivo general	1
1.2. Usuarios y decisiones habilitadas	1
1.3. Requisitos de arquitectura	2
2. Fuentes de datos	2
2.1. Calidad y transformaciones iniciales	3
3. Arquitectura integral del sistema	3
4. Descripción de las capas	5
4.1. Ingesta y transporte	5
4.2. Zona Bronce	5
4.3. Procesamiento Bronce a Plata	5
4.4. Zona Plata	5
5. Analítica avanzada y MLflow	5
5.1. Modelo 1: forecasting de precios a dos semanas	6
5.2. Modelo 2: clustering de productos	6
5.3. Modelo 3: clasificación binaria de alertas	6
5.4. Gestión de experimentos con MLflow	6
6. Zona Oro y consumo	7
6.1. Reglas de los KPIs	7
6.2. Vistas implementadas del dashboard Streamlit	7
7. Linaje, seguridad y operación	8
7.1. Consideraciones no funcionales	8
8. Plan de trabajo por semana	8
9. Estado actual, brechas y dependencias	9
10.Referencias y artefactos usados	10

1. Propósito y alcance

El proyecto *Food Price Forecasting Peru* diseña una solución de Big Data para integrar tres señales complementarias: precios mayoristas de alimentos, variables climáticas de zonas productoras y publicaciones de Twitter/X relacionadas con precios y canasta básica. El sistema organiza la información en un Data Lake con arquitectura Medallion, procesa los datos con Apache Spark, aplica modelos de Machine Learning y NLP, registra los experimentos con MLflow y publica los resultados mediante un dashboard interactivo desarrollado en Streamlit.

Este documento corresponde al entregable de arquitectura. Presenta el flujo de extremo a extremo, las fuentes con URL, formato, frecuencia y volumen, la descripción de las zonas Bronce, Plata y Oro, los componentes de analítica avanzada y el plan de trabajo por semana. La versión actual incorpora los notebooks del **Modelo 3 de clasificación binaria** y de la **Zona Oro**, que ya fueron ejecutados y dejaron salidas persistidas en Google Cloud Storage, así como el dashboard final en Streamlit con seis vistas. El equipo realizó además una prueba funcional con datos nuevos para verificar la actualización de la información mostrada.

Pregunta central

¿Es posible anticipar el precio mayorista de los principales alimentos agrícolas en Lima a dos semanas, identificar los productos más volátiles y detectar con anticipación una subida superior al 10 % mediante la integración de precios, clima y sentimiento social?

1.1. Objetivo general

Diseñar e implementar una arquitectura Big Data escalable que integre datos estructurados, series meteorológicas y texto libre para pronosticar precios de alimentos, segmentar productos por volatilidad y generar alertas binarias de alza, dejando los resultados preparados para su consumo directo desde un dashboard ejecutivo e interactivo desarrollado en Streamlit.

1.2. Usuarios y decisiones habilitadas

- **MIDAGRI y gestores públicos:** priorizar productos y semanas que requieren vigilancia.
- **Administradores de mercados:** anticipar variaciones relevantes y revisar productos con mayor volatilidad.
- **Analistas y periodistas:** consultar series, factores climáticos y percepción social.
- **Ciudadanía:** acceder a información comprensible sobre tendencias y alertas de precios.

1.3. Requisitos de arquitectura

Cuadro 1: Requisitos funcionales y tecnológicos del sistema

Dimensión	Requisito aplicado al proyecto
Tipos de dato	Series de precios, series climáticas/sensores y texto libre con metadatos.
Almacenamiento	Google Cloud Storage con Data Lake Medallion: Bronce, Plata y Oro.
Procesamiento	Apache Spark/PySpark como motor central; Spark SQL para agregaciones y KPIs.
Analítica	Forecasting, clustering y clasificación binaria; experimentos registrados en MLflow.
Consumo	Dashboard Streamlit con seis vistas interactivas, navegación lateral, actualización manual y refresco automático de la vista principal cada cinco minutos.
Actualización	El dashboard fue probado con datos nuevos; permite actualización manual y refresco automático de la Vista 1 cada cinco minutos. Pub/Sub para tweets se conserva como componente planificado de streaming.

2. Fuentes de datos

El inventario se elaboró a partir de los notebooks ejecutados y de las fuentes oficiales propuestas para el dominio de precios de alimentos. Los volúmenes son observados en la ejecución cuando existe evidencia; cuando no se dispone del tamaño físico, se reportan filas o archivos como medida de volumen.

Cuadro 2: Inventario de fuentes de datos

Fuente	Contenido	Formato / tipo	Frecuencia	Volumen observado y URL
SISAP – MIDA-GRI	Precios mayoristas de alimentos en mercados de Lima.	XLS; datos estructurados y serie temporal.	Fuente diaria; carga histórica por lote.	10 archivos, 35,994 registros crudos y 34,969 registros mapeados. https://sistemas.midagri.gob.pe/sisap
SENAMHI	Temperatura máxima y mínima, humedad, precipitación y eventos climáticos de zonas productoras.	CSV; series meteorológicas.	Datos diarios, agregados semanalmente.	7 archivos/estaciones, 18,841 observaciones, periodo 2015–2024. https://www.senamhi.gob.pe/?p=descarga-datos-hidrometeorologicos
Twitter / X	Publicaciones sobre precios de alimentos, con texto, fecha, likes, retweets y términos de búsqueda.	JSON; texto libre y metadatos.	Histórico batch; streaming propuesto.	5,133 registros crudos y 5,132 limpios; 465 semanas agregadas. https://developer.twitter.com

2.1. Calidad y transformaciones iniciales

Cuadro 3: Tratamientos de calidad por fuente

Fuente	Tratamiento principal	Control de calidad
SISAP	Lectura robusta de archivos XLS, normalización de fechas y precios, estandarización del producto y mapeo a mercado, distrito, ubigeo y región climática.	Se excluyen precios no válidos y registros sin correspondencia; el pipeline conserva el archivo de origen para trazabilidad.
SENAMHI	Estandarización de columnas, conversión de códigos sin dato a nulo, cálculo de temperatura media, heladas y lluvia intensa.	Validación de rangos, fechas y cobertura por región; agregación por año y semana.
Twitter / X	Eliminación de duplicados, limpieza de URL, menciones y signos; clasificación BERT y agregación semanal.	Verificación de texto no vacío, fecha válida y consistencia entre conteos de sentimiento.

3. Arquitectura integral del sistema

La Figura 1 presenta todas las capas funcionales: fuentes, ingesta, almacenamiento Bronze, procesamiento distribuido, Zona Plata, analítica avanzada, MLflow, Zona Oro y consumo. Las líneas discontinuas indican componentes que aún están pendientes de integración, principalmente el flujo de casi tiempo real mediante Pub/Sub.




Figura 1: Arquitectura de extremo a extremo actualizada del sistema. Las líneas discontinuas representan componentes planificados.

4. Descripción de las capas

4.1. Ingesta y transporte

La ingesta histórica se realiza en modo batch mediante descarga o carga directa hacia Google Cloud Storage. SISAP y SENAMHI se cargan como archivos XLS y CSV, respectivamente; los tweets se consolidan en un JSON. Para cumplir el requisito de una vista en casi tiempo real, se mantiene como diseño objetivo un flujo de GCP Pub/Sub que reciba nuevos tweets y los escriba en micro-lotes en la Zona Bronce.

4.2. Zona Bronce

La Zona Bronce conserva los archivos exactamente como llegan desde las fuentes. No se sobrescriben ni se transforman, lo que permite reproducibilidad y auditoría.

Cuadro 4: Organización de la Zona Bronce

Conjunto	Ruta en Google Cloud Storage	Formato
SISAP	gs://food-price-peru-2025-01/bronce/sisap/	XLS
SENAMHI	gs://food-price-peru-2025-01/bronce/senamhi/	CSV
Tweets	gs://food-price-peru-2025-01/bronce/tweets/bronce_tweets_precios_lima.json	JSON

4.3. Procesamiento Bronce a Plata

- SISAP:** lectura de archivos, estandarización, mapeo geográfico y agregación semanal por producto.
- SENAMHI:** limpieza de variables meteorológicas, cálculo de indicadores de helada y lluvia intensa y agregación semanal por región.
- Integración:** unión por región climática, año y semana; creación de rezagos de precios, medias móviles, volatilidad, estacionalidad y objetivos a dos semanas.
- Tweets:** limpieza textual, clasificación de sentimiento con BERT en español y agregación semanal.
- Persistencia:** escritura en Parquet para lectura columnar y procesamiento distribuido eficiente.

4.4. Zona Plata

Cuadro 5: Datasets principales de la Zona Plata

Dataset	Ruta relativa / propósito	Volumen
precios_spark	Precios limpios y enriquecidos para agregaciones semanales.	Base diaria procesada.
precios_clima_parquet	Integración semanal de precios y clima.	5,225 filas.
matriz_aprendizaje_forecasting	Features, rezagos y objetivos para Modelos 1 y 3.	4,697 filas.
tweets_sentimiento	Tweets limpios con etiqueta y puntuación de sentimiento.	5,132 filas.
tweets_sentimiento_semanal	Indicadores semanales de volumen y sentimiento.	465 filas.

5. Analítica avanzada y MLflow

5.1. Modelo 1: forecasting de precios a dos semanas

El Modelo 1 compara Regresión Lineal, Random Forest y XGBoost sobre una matriz que integra precio, clima y sentimiento. Tras excluir productos no agrícolas y aplicar un corte temporal, el mejor resultado fue la Regresión Lineal.

Cuadro 6: Comparación del Modelo 1

Algoritmo	RMSE	MAE	R^2
Regresión Lineal	1.0169	0.3472	0.8591
XGBoost	1.2363	0.3962	0.7918
Random Forest	1.2471	0.3982	0.7881

El artefacto ganador y la lista de variables se almacenan en `gs://food-price-peru-2025-01/oro/modelos/` y los experimentos quedan registrados en MLflow.

5.2. Modelo 2: clustering de productos

El Modelo 2 construye perfiles por producto usando precio promedio histórico, volatilidad, máximo y mínimo. Compara KMeans y clustering aglomerativo para varios valores de K . El modelo seleccionado fue **KMeans con $K = 2$** , con Silhouette Score de **0.536**. La tabla final conserva seis productos agrícolas; el Ajo Criollo o Napurí forma el grupo de mayor volatilidad.

5.3. Modelo 3: clasificación binaria de alertas

El Modelo 3 responde si el precio subirá más de 10% en las dos semanas siguientes. La matriz original contiene 4,697 filas, de las cuales 742 son alertas (15.80%). Después de excluir productos industriales y proteínas, se utilizan 2,341 registros agrícolas: 1,742 para entrenamiento y 599 para prueba.

Cuadro 7: Comparación del Modelo 3 optimizado

Algoritmo	AUC-ROC	F1-Score
Random Forest optimizado	0.6756	0.7135
GBT optimizado	0.6821	0.6720
Regresión Logística	0.6324	0.5811

El notebook selecciona GBT optimizado por mayor AUC-ROC. La validación cruzada alcanza un AUC promedio de 0.7122. Los scores se escriben en `gs://food-price-peru-2025-01/oro/alerta_binaria_productos/` con 599 registros y columnas de alerta real, alerta predicha y probabilidad.

5.4. Gestión de experimentos con MLflow

MLflow centraliza parámetros, métricas y artefactos de los tres modelos. Para regresión se registran RMSE, MAE y R^2 ; para clustering, Silhouette Score; para clasificación, AUC-ROC y F1. También se guardan modelos serializados, gráficos, listas de features y archivos de respaldo de las ejecuciones.

6. Zona Oro y consumo

El notebook `07_zona_oro.ipynb` construye y valida las tres tablas principales de consumo. El dashboard en Streamlit consume `kpi_precios`, `kpi_sentimiento` y `clusters_productos`, además de métricas de MLflow. El Modelo 3 deja una cuarta salida de scores en Oro, disponible para ampliar las alertas probabilísticas del tablero.

Cuadro 8: Objetos implementados en la Zona Oro

Objeto	Contenido principal	Filas	Estado
kpi_precios	Año, semana, producto, precio promedio, variación porcentual y semáforo NORMAL/ATENCIÓN/ALERTA.	3,132	Implementado
kpi_sentimiento	Año, semana, sentimiento promedio, número de tweets y porcentaje de negativos.	465	Implementado
clusters_productos	Producto, cluster, precio histórico, volatilidad, máximos, mínimos, modelo y Silhouette.	6	Implementado
alerta_binaria_productos	Producto, fecha/semana, alerta real, alerta predicha y probabilidad de alza.	599	Implementado
modelos/	Modelo de forecasting, features y artefactos serializados.	—	Implementado

6.1. Reglas de los KPIs

Para `kpi_precios`, el precio promedio se calcula por producto, año y semana. La variación se compara con la semana anterior. Una subida menor a 5 % se clasifica como NORMAL; entre 5 % y menos de 10 %, como ATENCIÓN; y desde 10 %, como ALERTA. Las caídas de precio permanecen como NORMAL porque el objetivo operativo está orientado a detectar alzas.

6.2. Vistas implementadas del dashboard Streamlit

Cuadro 9: Vistas implementadas y preguntas asociadas

N.	Vista	Pregunta que responde	Fuente principal
1	Alertas en tiempo real	¿Qué productos requieren atención o alerta en la última semana registrada?	kpi_precios
2	Ranking de precios	¿Qué productos presentan el mayor precio promedio por kilogramo en el último corte?	kpi_precios
3	Segmentación por volatilidad	¿Qué productos comparten perfiles similares de precio histórico y volatilidad?	clusters_productos
4	Histórico de precios	¿Cómo evolucionó semanalmente el precio de cada producto entre 2015 y 2025?	kpi_precios
5	Sentimiento en redes	¿Cómo evolucionan el sentimiento promedio y el porcentaje de tweets negativos?	kpi_sentimiento
6	Salud del sistema	¿Qué métricas obtuvieron los modelos de forecasting y clasificación registrados en MLflow?	Métricas MLflow embebidas

La capa de consumo fue implementada en Streamlit y ejecutada localmente mediante `localhost:8501`. La aplicación utiliza un menú lateral para navegar entre seis vistas y presenta gráficos interactivos para alertas, ranking, segmentación, evolución histórica, sentimiento y salud del sistema. Incluye el botón *Actualizar datos ahora* y la Vista 1 se refresca automáticamente cada cinco minutos. El equipo probó la aplicación con una nueva carga de datos y verificó que los valores visualizados se actualizaran, confirmando la conexión funcional entre las salidas de la Zona Oro y el dashboard. Esta actualización periódica no equivale todavía a una ingesta de eventos en streaming; la integración de Pub/Sub se mantiene como mejora de arquitectura.




Figura 2: Prueba funcional del dashboard Streamlit. La imagen muestra la vista de segmentación por volatilidad, la navegación lateral con seis vistas, el botón de actualización y la indicación de refresco automático cada cinco minutos.

7. Linaje, seguridad y operación

Cuadro 10: Linaje resumido por dominio de datos

Dominio	Bronce	Plata	Oro / consumo
Precios	XLS de SISAP	Precios limpios, agregación semanal, lags, medias móviles y targets	kpi_precios, modelos y scores
Clima	CSV de SE-NAMHI	Variables climáticas limpias y agregadas; integración producto-región-semana	Features del forecast, clustering y clasificación
Texto	JSON de tweets	Tweets con sentimiento y resumen semanal	kpi_sentimiento y feature social

7.1. Consideraciones no funcionales

- **Reproducibilidad:** notebooks versionados y experimentos registrados en MLflow.
- **Escalabilidad:** Spark y almacenamiento Parquet en GCS.
- **Trazabilidad:** archivo de origen, rutas, conteos de entrada/salida y versión de modelo.
- **Seguridad:** uso de identidades de servicio y exclusión de credenciales del repositorio.
- **Calidad:** validación de esquema, nulos, rangos, fechas y conteos antes de promover datos.
- **Disponibilidad:** Streamlit consume las salidas preparadas en Oro y evita ejecutar procesos ETL o cálculos distribuidos pesados durante la interacción del usuario.

8. Plan de trabajo por semana

Cuadro 11: Plan de trabajo actualizado

Sem.	Fase	Actividades principales	Estado
8	Comprensión del problema	Definir problema, stakeholders, preguntas analíticas y fuentes confirmadas.	Completado
9	Arquitectura	Diseñar el flujo completo, fuentes, Medallion, componentes analíticos y plan semanal.	Actualizado
10	Ingesta y Bronce	Consolidar cargas SISAP, SENAMHI y tweets; documentar esquemas y conteos.	Avanzado
11	ETL y Plata	Ejecutar limpieza, integración, feature engineering y persistencia Parquet.	Completado
12-13	NLP y Modelo 1	Procesar sentimiento; comparar modelos de forecasting y registrar MLflow.	Completado
14	Modelos 2 y 3	Ejecutar clustering, clasificación binaria, evaluación y persistencia.	Completado
14	Zona Oro	Construir KPIs, clusters y scores; validar rutas y conteos.	Completado
15	Dashboard Streamlit	Implementar seis vistas, navegación lateral, actualización manual, refresco automático y conexión con las salidas de Oro.	Completado
15	Prueba de actualización	Cargar datos nuevos y validar su actualización en las vistas del dashboard.	Completado
15	Streaming	Activar Pub/Sub para una ingesta de eventos realmente continua.	Pendiente
16	Evaluación y despliegue	Validación integral, reporte final, demo y documentación de impacto.	Pendiente

9. Estado actual, brechas y dependencias

Cuadro 12: Estado del proyecto después de incorporar los nuevos scripts

Componente	Situación observada	Acción pendiente
Zona Bronce	Fuentes y rutas evidenciadas en GCS.	Incorporar scripts de recolección al repositorio para ejecución reproducible.
Zona Plata	Precios, clima y NLP integrados en Parquet.	Añadir pruebas automáticas de calidad y esquema.
Modelos 1, 2 y 3	Implementados, evaluados y registrados con MLflow.	Consolidar un único registro o servidor de tracking para el equipo.
Zona Oro	KPIs, clusters, scores y artefactos poblados y validados.	Mantener contratos de esquema estables para el dashboard.
Streaming	Diseñado con Pub/Sub.	Implementar y demostrar una actualización casi real.
Dashboard	Aplicación Streamlit implementada con seis vistas, navegación lateral, botón de actualización y refresco automático cada cinco minutos en la Vista 1. Fue probada con datos nuevos.	Publicar la aplicación en un servicio accesible fuera del entorno local y mantener estable la conexión con las tablas Oro.

Conclusión de arquitectura

La arquitectura cumple los elementos centrales del proyecto: integra tres tipos de dato, usa un Data Lake Medallion en GCS, procesa con Spark, registra tres modelos con MLflow, dispone de una Zona Oro poblada y cuenta con un dashboard Streamlit funcional. La aplicación fue probada con datos nuevos, dispone de actualización manual y refresco automático de la vista principal cada cinco minutos. Las brechas restantes son desplegar el dashboard fuera del entorno local y completar la ingesta continua mediante Pub/Sub. Por lo tanto, el flujo analítico y su capa de visualización se encuentran funcionalmente integrados y validados.

10. Referencias y artefactos usados

Referencias

- [1] Guevara Ponce, V. *Proyecto Final – Sistema Integral de Big Data Analytics: Solución a Problemas Reales del Perú*. Documento del curso Big Data.
- [2] MIDAGRI. Sistema de Abastecimiento y Precios (SISAP). <https://sistemas.midagri.gob.pe/sisap>
- [3] SENAMHI. Descarga de datos hidrometeorológicos. <https://www.senamhi.gob.pe/?p=descarga-datos-hidrometeorologicos>
- [4] X Developer Platform. <https://developer.twitter.com>
- [5] Apache Spark. <https://spark.apache.org>
- [6] MLflow. <https://mlflow.org>
- [7] Streamlit. <https://streamlit.io>
- [8] Repositorio del proyecto. <https://github.com/AlKstudent/food-price-forecasting-peru>

Archivos técnicos usados

- README.md
- 01_EDA_Exploratorio.ipynb
- 02_ETL_Bronce_a_Plata.ipynb
- 03_NLP_tweets_sentimiento.ipynb
- 04_Modelo_1_Forecasting.ipynb
- 05_modelo2_clustering.ipynb
- 06_modelo3_clasificacion_binaria.ipynb
- 07_zona_oro.ipynb
- Evidencia visual y prueba funcional del dashboard Streamlit con datos nuevos.
- Respaldos de ejecuciones MLflow de los modelos.

Fin del documento