

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Universidad del Perú. Decana de América

FACULTAD DE CIENCIAS MATEMÁTICAS

ESCUELA PROFESIONAL DE ESTADÍSTICA



Sistema Big Data para el pronóstico y la alerta temprana de precios de alimentos en el Perú

Documento de Arquitectura

INTEGRANTES DEL GRUPO 5:

MEDRANO RIVERA, ALEXIS

QUISPE VILLENA, DANIEL

RIVERA LAURA, ANDREW

GARRIDO SILVA, CARLOS LUIS ESTEFANO

ASIGNATURA:

Big Data

DOCENTE:

GUEVARA PONCE, VÍCTOR

2026 – I

Lima, Perú

Índice

1. Propósito y alcance	1
1.1. Objetivo general	1
1.2. Usuarios y decisiones habilitadas	1
1.3. Requisitos de arquitectura	1
2. Fuentes de datos	2
2.1. Calidad y transformaciones iniciales	2
3. Arquitectura integral del sistema	2
4. Descripción de las capas	4
4.1. Ingesta y transporte	4
4.2. Zona Bronce	4
4.3. Procesamiento Bronce a Plata	4
4.4. Zona Plata	4
5. Analítica avanzada y MLflow	4
5.1. Modelo 1: forecasting de precios a dos semanas	5
5.2. Modelo 2: clustering de productos	5
5.3. Modelo 3: clasificación binaria de alertas	5
5.4. Gestión de experimentos con MLflow	5
6. Zona Oro y consumo	6
6.1. Reglas de los KPIs	6
6.2. Vistas previstas del dashboard	6
7. Linaje, seguridad y operación	6
7.1. Consideraciones no funcionales	7
8. Plan de trabajo por semana	7
9. Estado actual, brechas y dependencias	8
10. Referencias y artefactos usados	8

1. Propósito y alcance

El proyecto *Food Price Forecasting Peru* diseña una solución de Big Data para integrar tres señales complementarias: precios mayoristas de alimentos, variables climáticas de zonas productoras y publicaciones de Twitter/X relacionadas con precios y canasta básica. El sistema organiza la información en un Data Lake con arquitectura Medallion, procesa los datos con Apache Spark, aplica modelos de Machine Learning y NLP, registra los experimentos con MLflow y publica resultados listos para un dashboard en Streamlit.

Este documento corresponde al entregable de arquitectura. Presenta el flujo de extremo a extremo, las fuentes con URL, formato, frecuencia y volumen, la descripción de las zonas Bronce, Plata y Oro, los componentes de analítica avanzada y el plan de trabajo por semana. La versión actual incorpora los nuevos notebooks del **Modelo 3 de clasificación binaria** y de la **Zona Oro**, que ya fueron ejecutados y dejaron salidas persistidas en Google Cloud Storage.

Pregunta central

¿Es posible anticipar el precio mayorista de los principales alimentos agrícolas en Lima a dos semanas, identificar los productos más volátiles y detectar con anticipación una subida superior al 10 % mediante la integración de precios, clima y sentimiento social?

1.1. Objetivo general

Diseñar e implementar una arquitectura Big Data escalable que integre datos estructurados, series meteorológicas y texto libre para pronosticar precios de alimentos, segmentar productos por volatilidad y generar alertas binarias de alza, dejando los resultados preparados para su consumo directo desde un dashboard ejecutivo.

1.2. Usuarios y decisiones habilitadas

- **MIDAGRI y gestores públicos:** priorizar productos y semanas que requieren vigilancia.
- **Administradores de mercados:** anticipar variaciones relevantes y revisar productos con mayor volatilidad.
- **Analistas y periodistas:** consultar series, factores climáticos y percepción social.
- **Ciudadanía:** acceder a información comprensible sobre tendencias y alertas de precios.

1.3. Requisitos de arquitectura

Cuadro 1: Requisitos funcionales y tecnológicos del sistema

Dimensión	Requisito aplicado al proyecto
Tipos de dato	Series de precios, series climáticas/sensores y texto libre con metadatos.
Almacenamiento	Google Cloud Storage con Data Lake Medallion: Bronce, Plata y Oro.
Procesamiento	Apache Spark/PySpark como motor central; Spark SQL para agregaciones y KPIs.
Analítica	Forecasting, clustering y clasificación binaria; experimentos registrados en MLflow.
Consumo	Dashboard Streamlit con al menos cinco vistas y una vista de salud del sistema.
Actualización	Ingesta batch implementada; Pub/Sub para tweets se conserva como componente planificado de casi tiempo real.

2. Fuentes de datos

El inventario se elaboró a partir de los notebooks ejecutados y de las fuentes oficiales propuestas para el dominio de precios de alimentos. Los volúmenes son observados en la ejecución cuando existe evidencia; cuando no se dispone del tamaño físico, se reportan filas o archivos como medida de volumen.

Cuadro 2: Inventario de fuentes de datos

Fuente	Contenido	Formato / tipo	Frecuencia	Volumen observado y URL
SISAP – MIDA-GRI	Precios mayoristas de alimentos en mercados de Lima.	XLS; datos estructurados y serie temporal.	Fuente diaria; carga histórica por lote.	10 archivos, 35,994 registros crudos y 34,969 registros mapeados. https://sistemas.midagri.gob.pe/sisap
SENAMHI	Temperatura máxima y mínima, humedad, precipitación y eventos climáticos de zonas productoras.	CSV; series meteorológicas.	Datos diarios, agregados semanalmente.	7 archivos/estaciones, 18,841 observaciones, periodo 2015–2024. https://www.senamhi.gob.pe/?p=descarga-datos-hidrometeorologicos
Twitter / X	Publicaciones sobre precios de alimentos, con texto, fecha, likes, retweets y términos de búsqueda.	JSON; texto libre y metadatos.	Histórico batch; streaming propuesto.	5,133 registros crudos y 5,132 limpios; 465 semanas agregadas. https://developer.twitter.com

2.1. Calidad y transformaciones iniciales

Cuadro 3: Tratamientos de calidad por fuente

Fuente	Tratamiento principal	Control de calidad
SISAP	Lectura robusta de archivos XLS, normalización de fechas y precios, estandarización del producto y mapeo a mercado, distrito, ubigeo y región climática.	Se excluyen precios no válidos y registros sin correspondencia; el pipeline conserva el archivo de origen para trazabilidad.
SENAMHI	Estandarización de columnas, conversión de códigos sin dato a nulo, cálculo de temperatura media, heladas y lluvia intensa.	Validación de rangos, fechas y cobertura por región; agregación por año y semana.
Twitter / X	Eliminación de duplicados, limpieza de URL, menciones y signos; clasificación BERT y agregación semanal.	Verificación de texto no vacío, fecha válida y consistencia entre conteos de sentimiento.

3. Arquitectura integral del sistema

La Figura 1 presenta todas las capas funcionales: fuentes, ingesta, almacenamiento Bronze, procesamiento distribuido, Zona Plata, analítica avanzada, MLflow, Zona Oro y consumo. Las líneas discontinuas indican componentes que aún están en desarrollo o pendientes de integración, principalmente Pub/Sub y el dashboard.




Figura 1: Arquitectura de extremo a extremo actualizada del sistema. Las líneas discontinuas representan componentes planificados.

4. Descripción de las capas

4.1. Ingesta y transporte

La ingesta histórica se realiza en modo batch mediante descarga o carga directa hacia Google Cloud Storage. SISAP y SENAMHI se cargan como archivos XLS y CSV, respectivamente; los tweets se consolidan en un JSON. Para cumplir el requisito de una vista en casi tiempo real, se mantiene como diseño objetivo un flujo de GCP Pub/Sub que reciba nuevos tweets y los escriba en micro-lotes en la Zona Bronce.

4.2. Zona Bronce

La Zona Bronce conserva los archivos exactamente como llegan desde las fuentes. No se sobrescriben ni se transforman, lo que permite reproducibilidad y auditoría.

Cuadro 4: Organización de la Zona Bronce

Conjunto	Ruta en Google Cloud Storage	Formato
SISAP	gs://food-price-peru-2025-01/bronce/sisap/	XLS
SENAMHI	gs://food-price-peru-2025-01/bronce/senamhi/	CSV
Tweets	gs://food-price-peru-2025-01/bronce/tweets/bronce_tweets_precios_lima.json	JSON

4.3. Procesamiento Bronce a Plata

1. **SISAP:** lectura de archivos, estandarización, mapeo geográfico y agregación semanal por producto.
2. **SENAMHI:** limpieza de variables meteorológicas, cálculo de indicadores de helada y lluvia intensa y agregación semanal por región.
3. **Integración:** unión por región climática, año y semana; creación de rezagos de precios, medias móviles, volatilidad, estacionalidad y objetivos a dos semanas.
4. **Tweets:** limpieza textual, clasificación de sentimiento con BERT en español y agregación semanal.
5. **Persistencia:** escritura en Parquet para lectura columnar y procesamiento distribuido eficiente.

4.4. Zona Plata

Cuadro 5: Datasets principales de la Zona Plata

Dataset	Ruta relativa / propósito	Volumen
precios_spark	Precios limpios y enriquecidos para agregaciones semanales.	Base diaria procesada.
precios_clima_parquet	Integración semanal de precios y clima.	5,225 filas.
matriz_aprendizaje_forecasting	Features, rezagos y objetivos para Modelos 1 y 3.	4,697 filas.
tweets_sentimiento	Tweets limpios con etiqueta y puntuación de sentimiento.	5,132 filas.
tweets_sentimiento_semanal	Indicadores semanales de volumen y sentimiento.	465 filas.

5. Analítica avanzada y MLflow

5.1. Modelo 1: forecasting de precios a dos semanas

El Modelo 1 compara Regresión Lineal, Random Forest y XGBoost sobre una matriz que integra precio, clima y sentimiento. Tras excluir productos no agrícolas y aplicar un corte temporal, el mejor resultado fue la Regresión Lineal.

Cuadro 6: Comparación del Modelo 1

Algoritmo	RMSE	MAE	R^2
Regresión Lineal	1.0169	0.3472	0.8591
XGBoost	1.2363	0.3962	0.7918
Random Forest	1.2471	0.3982	0.7881

El artefacto ganador y la lista de variables se almacenan en `gs://food-price-peru-2025-01/oro/modelos/` y los experimentos quedan registrados en MLflow.

5.2. Modelo 2: clustering de productos

El Modelo 2 construye perfiles por producto usando precio promedio histórico, volatilidad, máximo y mínimo. Compara KMeans y clustering aglomerativo para varios valores de K . El modelo seleccionado fue **KMeans con $K = 2$** , con Silhouette Score de **0.536**. La tabla final conserva seis productos agrícolas; el Ajo Criollo o Napurí forma el grupo de mayor volatilidad.

5.3. Modelo 3: clasificación binaria de alertas

El Modelo 3 responde si el precio subirá más de 10% en las dos semanas siguientes. La matriz original contiene 4,697 filas, de las cuales 742 son alertas (15.80%). Después de excluir productos industriales y proteínas, se utilizan 2,341 registros agrícolas: 1,742 para entrenamiento y 599 para prueba.

Cuadro 7: Comparación del Modelo 3 optimizado

Algoritmo	AUC-ROC	F1-Score
Random Forest optimizado	0.6756	0.7135
GBT optimizado	0.6821	0.6720
Regresión Logística	0.6324	0.5811

El notebook selecciona GBT optimizado por mayor AUC-ROC. La validación cruzada alcanza un AUC promedio de 0.7122. Los scores se escriben en `gs://food-price-peru-2025-01/oro/alerta_binaria_productos/` con 599 registros y columnas de alerta real, alerta predicha y probabilidad.

5.4. Gestión de experimentos con MLflow

MLflow centraliza parámetros, métricas y artefactos de los tres modelos. Para regresión se registran RMSE, MAE y R^2 ; para clustering, Silhouette Score; para clasificación, AUC-ROC y F1. También se guardan modelos serializados, gráficos, listas de features y archivos de respaldo de las ejecuciones.

6. Zona Oro y consumo

El notebook 07_zona_oro.ipynb construye y valida las tres tablas que alimentan directamente el dashboard. Además, el Modelo 3 deja una cuarta salida de scores en Oro.

Cuadro 8: Objetos implementados en la Zona Oro

Objeto	Contenido principal	Filas	Estado
kpi_precios	Año, semana, producto, precio promedio, variación porcentual y semáforo NORMAL/ATENCIÓN/ALERTA.	3,132	Implementado
kpi_sentimiento	Año, semana, sentimiento promedio, número de tweets y porcentaje de negativos.	465	Implementado
clusters_productos	Producto, cluster, precio histórico, volatilidad, máximos, mínimos, modelo y Silhouette.	6	Implementado
alerta_binaria_productos	Producto, fecha/semana, alerta real, alerta predicha y probabilidad de alza.	599	Implementado
modelos/	Modelo de forecasting, features y artefactos serializados.	—	Implementado

6.1. Reglas de los KPIs

Para **kpi_precios**, el precio promedio se calcula por producto, año y semana. La variación se compara con la semana anterior. Una subida menor a 5 % se clasifica como NORMAL; entre 5 % y menos de 10 %, como ATENCIÓN; y desde 10 %, como ALERTA. Las caídas de precio permanecen como NORMAL porque el objetivo operativo está orientado a detectar alzas.

6.2. Vistas previstas del dashboard

Cuadro 9: Vistas de consumo y preguntas asociadas

N.	Pregunta que responde	Dataset principal
1	¿Qué productos presentan variaciones que requieren atención o alerta?	kpi_precios
2	¿Cuál será el precio de cada producto dentro de dos semanas?	Modelo 1 y artefactos de modelos/
3	¿Qué productos comparten un perfil de riesgo y volatilidad?	clusters_productos
4	¿Qué factores climáticos y temporales explican el comportamiento?	Zona Plata y features del Modelo 1
5	¿Cómo evoluciona la percepción social sobre los precios?	kpi_sentimiento
6	¿Cuál es la probabilidad de una subida superior al 10 %?	alerta_binaria_productos
7	¿Está actualizado y saludable el sistema?	Metadatos de ejecución y control de ingesta

7. Linaje, seguridad y operación

Cuadro 10: Linaje resumido por dominio de datos

Dominio	Bronce	Plata	Oro / consumo
Precios	XLS de SISAP	Precios limpios, agregación semanal, lags, medias móviles y targets	kpi_precios, modelos y scores
Clima	CSV de SE-NAMHI	Variables climáticas limpias y agregadas; integración producto-región-semana	Features del forecast, clustering y clasificación
Texto	JSON de tweets	Tweets con sentimiento y resumen semanal	kpi_sentimiento y feature social

7.1. Consideraciones no funcionales

- **Reproducibilidad:** notebooks versionados y experimentos registrados en MLflow.
- **Escalabilidad:** Spark y almacenamiento Parquet en GCS.
- **Trazabilidad:** archivo de origen, rutas, conteos de entrada/salida y versión de modelo.
- **Seguridad:** uso de identidades de servicio y exclusión de credenciales del repositorio.
- **Calidad:** validación de esquema, nulos, rangos, fechas y conteos antes de promover datos.
- **Disponibilidad:** el dashboard debe leer exclusivamente Oro para evitar cálculos pesados en línea.

8. Plan de trabajo por semana

Cuadro 11: Plan de trabajo actualizado

Sem.	Fase	Actividades principales	Estado
8	Comprensión del problema	Definir problema, stakeholders, preguntas analíticas y fuentes confirmadas.	Completado
9	Arquitectura	Diseñar el flujo completo, fuentes, Medallion, componentes analíticos y plan semanal.	Actualizado
10	Ingesta y Bronce	Consolidar cargas SISAP, SENAMHI y tweets; documentar esquemas y conteos.	Avanzado
11	ETL y Plata	Ejecutar limpieza, integración, feature engineering y persistencia Parquet.	Completado
12–13	NLP y Modelo 1	Procesar sentimiento; comparar modelos de forecasting y registrar MLflow.	Completado
14	Modelos 2 y 3	Ejecutar clustering, clasificación binaria, evaluación y persistencia.	Completado
14	Zona Oro	Construir KPIs, clusters y scores; validar rutas y conteos.	Completado
15	Dashboard	Implementar vistas Streamlit y conectarlas exclusivamente a Oro.	Pendiente
15	Streaming	Activar Pub/Sub o demostrar una actualización casi real.	Pendiente
16	Evaluación y despliegue	Validación integral, reporte final, demo y documentación de impacto.	Pendiente

9. Estado actual, brechas y dependencias

Cuadro 12: Estado del proyecto después de incorporar los nuevos scripts

Componente	Situación observada	Acción pendiente
Zona Bronce	Fuentes y rutas evidenciadas en GCS.	Incorporar scripts de recolección al repositorio para ejecución reproducible.
Zona Plata	Precios, clima y NLP integrados en Parquet.	Añadir pruebas automáticas de calidad y esquema.
Modelos 1, 2 y 3	Implementados, evaluados y registrados con MLflow.	Consolidar un único registro o servidor de tracking para el equipo.
Zona Oro	KPIs, clusters, scores y artefactos poblados y validados.	Mantener contratos de esquema estables para el dashboard.
Streaming	Diseñado con Pub/Sub.	Implementar y demostrar una actualización casi real.
Dashboard	Carpeta creada, sin código en el repositorio actual.	Desarrollar las vistas y conectar las tablas Oro.

Conclusión de arquitectura

La arquitectura cumple los elementos centrales del proyecto: integra tres tipos de dato, usa un Data Lake Medallion en GCS, procesa con Spark, registra tres modelos con MLflow y ya dispone de una Zona Oro poblada. Las brechas restantes se concentran en el dashboard y en la demostración de ingesta casi real mediante Pub/Sub. Por lo tanto, el backend analítico está listo para ser consumido por la capa de visualización.

10. Referencias y artefactos usados

Referencias

- [1] Guevara Ponce, V. *Proyecto Final – Sistema Integral de Big Data Analytics: Solución a Problemas Reales del Perú*. Documento del curso Big Data.
- [2] MIDAGRI. Sistema de Abastecimiento y Precios (SISAP). <https://sistemas.midagri.gob.pe/sisap>
- [3] SENAMHI. Descarga de datos hidrometeorológicos. <https://www.senamhi.gob.pe/?p=descarga-datos-hidrometeorologicos>
- [4] X Developer Platform. <https://developer.twitter.com>
- [5] Apache Spark. <https://spark.apache.org>
- [6] MLflow. <https://mlflow.org>
- [7] Streamlit. <https://streamlit.io>
- [8] Repositorio del proyecto. <https://github.com/AlKstudent/food-price-forecasting-peru>

Archivos técnicos usados

- README.md
- 01_EDA_Exploratorio.ipynb

- 02_ETL_Bronce_a_Plata.ipynb
- 03_NLP_tweets_sentimiento.ipynb
- 04_Modelo_1_Forecasting.ipynb
- 05_modelo2_clustering.ipynb
- 06_modelo3_clasificacion_binaria.ipynb
- 07_zona_oro.ipynb
- RespalDOS de ejecuciones MLflow de los modelos.

Fin del documento