

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

Universidad del Perú. Decana de América

FACULTAD DE CIENCIAS MATEMÁTICAS

ESCUELA PROFESIONAL DE ESTADÍSTICA



Sistema Big Data para el pronóstico y la alerta temprana de precios de alimentos en el Perú

Reporte Final – Metodología CRISP-DM

INTEGRANTES DEL GRUPO 5:

MEDRANO RIVERA, ALEXIS

QUISPE VILLENA, DANIEL

RIVERA LAURA, ANDREW

GARRIDO SILVA, CARLOS LUIS ESTEFANO

ASIGNATURA:

Big Data

DOCENTE:

GUEVARA PONCE, VÍCTOR

2026 – I

Lima, Perú

Índice

Resumen ejecutivo	1
1. Fase 1: comprensión del problema	1
2. Fase 2: comprensión de los datos	2
3. Fase 3: preparación de los datos	3
4. Fase 4: modelado y registro en MLflow	4
5. Fase 5: evaluación y resultados del dashboard	6
6. Fase 6: despliegue, prueba y operación	10
7. Evaluación integral, impacto y limitaciones	11
8. Conclusiones y recomendaciones	12
Referencias y artefactos técnicos	13

Resumen ejecutivo

El proyecto desarrolla un sistema de Big Data para monitorear y anticipar variaciones en el precio mayorista de seis alimentos agrícolas en Lima. La solución integra tres señales: precios de SISAP–MIDAGRI, variables meteorológicas de SENAMHI y publicaciones de Twitter/X procesadas mediante análisis de sentimiento. Los datos se organizan en un Data Lake con arquitectura Medallion sobre Google Cloud Storage (GCS), se transforman con Apache Spark/PySpark, se modelan mediante forecasting, clustering y clasificación binaria, y se registran en MLflow.

El pipeline procesó 35,994 registros crudos de precios, 18,841 observaciones meteorológicas y 5,133 publicaciones. Después de la limpieza se obtuvieron 34,969 precios utilizables y 5,132 tweets; la Zona Plata contiene 5,225 registros integrados de precios y clima y una matriz de aprendizaje de 4,697 filas. La Zona Oro quedó poblada con 3,132 KPI semanales de precios, 465 KPI de sentimiento, seis perfiles de clustering y 599 scores de alerta.

El Modelo 1 seleccionó Regresión Lineal con RMSE de 1.0169 S/ por kg, MAE de 0.3472 y $R^2 = 0.8591$. El Modelo 2 seleccionó KMeans con $K = 2$ y Silhouette de 0.536; el Ajo Criollo o Napurí forma el grupo de mayor volatilidad. El Modelo 3 optimizado seleccionó GBT por AUC-ROC de 0.6821, con F1 de 0.6720 y AUC promedio de validación cruzada de 0.7122. El dashboard se implementó en Streamlit y se probó con un nuevo corte de datos; el HTML entregado replica las mismas seis vistas y contiene los datos que se utilizan en este reporte para reconstruir los gráficos sin insertar capturas de pantalla.

En el último corte disponible, 2025-S52, cinco productos se clasificaron como NORMAL y el Camote Morado como ATENCIÓN por una subida semanal de 5.95 %. El sistema cumple el objetivo académico de integrar datos heterogéneos, procesamiento distribuido, tres modelos y una capa de consumo funcional. La principal limitación es que la ingesta sigue siendo batch: el refresco de la interfaz no equivale a streaming continuo de origen.

1. Fase 1: comprensión del problema

1.1. Problema, propósito y pregunta central

El precio de los alimentos es sensible a cambios de oferta, estacionalidad, clima y expectativas sociales. Cuando estas señales se revisan por separado, la respuesta puede llegar después de que el aumento ya se trasladó al consumidor. El proyecto busca reducir ese desfase mediante un sistema que integra información histórica y genera resultados accionables.

Pregunta central

¿Es posible anticipar el precio mayorista de los principales alimentos agrícolas en Lima a dos semanas, identificar los productos más volátiles y detectar una subida superior al 10 % mediante la integración de precios, clima y sentimiento social?

1.2. Objetivo general y usuarios

El objetivo general es implementar una arquitectura Big Data reproducible que integre tres tipos de datos, prepare las señales en un Data Lake Medallion, compare modelos analíticos y publique resultados en un dashboard. Los usuarios potenciales son gestores de MIDAGRI, administradores de mercados, analistas, periodistas y ciudadanía interesada en el costo de los alimentos.

1.3. Preguntas analíticas y métricas de éxito

1. ¿Qué precisión alcanza el pronóstico del precio a dos semanas y qué algoritmo generaliza mejor?
2. ¿Qué productos presentan perfiles de precio y volatilidad semejantes?
3. ¿Qué producto presenta el mayor riesgo histórico por volatilidad?

4. ¿Qué proporción de observaciones corresponde a una subida futura superior al 10 %?

5. ¿Qué clasificador discrimina mejor las semanas con alerta?

6. ¿Cuál es la composición y evolución del sentimiento social sobre precios?

7. ¿La matriz integrada queda disponible sin nulos críticos para el modelamiento?

8. ¿Las salidas de Oro pueden consumirse sin cálculos pesados en la interfaz?

9. ¿Qué muestran las seis vistas del dashboard en el último corte?

10. ¿El sistema puede recargarse cuando se incorpora un nuevo corte de datos?

Las métricas de éxito fueron RMSE, MAE y R^2 para forecasting; Silhouette para clustering; AUC-ROC y F1 para clasificación; controles de calidad y conteos por zona; y funcionamiento de seis vistas, incluida la salud de los modelos.

2. Fase 2: comprensión de los datos

2.1. Fuentes, formatos y cobertura

Cuadro 1: Inventario de fuentes y volumen procesado

Fuente	Contenido	Formato / tipo	Volumen	Cobertura y uso
SISAP–MIDAGRI	Precios mayoristas de alimentos en mercados de Lima.	XLS; estructurado y serie temporal.	10 archivos; 35,994 filas crudas; 34,969 mapeadas.	Base diaria para agregación semanal, rezagos y targets.
SENAMHI	Temperatura, humedad, precipitación y eventos climáticos.	CSV; sensores y series temporales.	7 estaciones; 18,841 observaciones.	Periodo 2015–2024; agregación por región y semana.
Twitter/X	Publicaciones sobre precios, alimentos y canasta básica.	JSON; texto libre y metadatos.	5,133 crudas; 5,132 limpias.	Periodo 2015–2024; sentimiento semanal.

2.2. Calidad, perfilado y sentimiento

En SISAP se normalizaron fechas, precios y productos, y se preservó el archivo de origen para trazabilidad. En SENAMHI se transformaron códigos sin dato a nulos, se validaron rangos y se calcularon variables semanales. En Twitter/X se eliminó un duplicado, se limpiaron enlaces, menciones y signos y no quedaron nulos en ID, texto limpio, score, etiqueta ni semana.

La clasificación de 5,132 publicaciones produjo 2,458 neutrales (47.9 %), 2,239 negativas (43.6 %) y 435 positivas (8.5 %). El promedio ponderado de sentimiento calculado desde las 465 semanas del dashboard es -0.352 y el porcentaje negativo ponderado es 43.63 %. Estos valores describen una conversación predominantemente neutral-negativa; no constituyen por sí solos evidencia causal sobre los precios.




Figura 1: Distribución de sentimiento en las publicaciones procesadas.

Cuadro 2: Controles principales de calidad

Problema	Tratamiento aplicado	Resultado
Productos y formatos heterogéneos	Estandarización, diccionario de mapeo y validación de precios.	34,969 precios utilizables.
Faltantes climáticos por semana	Unión por región, año y semana e imputación en la matriz.	Matriz final de 4,697 filas.
Semanas sin actividad social	Imputación neutral o cero según la variable.	Sin nulos críticos en el conjunto final.
Clase de alerta desbalanceada	Evaluación con AUC y F1 en lugar de accuracy.	742 alertas de 4,697 observaciones (15.80 %).

3. Fase 3: preparación de los datos

3.1. Arquitectura Medallion y procesamiento

La Zona Bronce conserva XLS, CSV y JSON sin transformación. Spark ejecuta limpieza, estandarización, agregación semanal, integración por región climática, ingeniería de variables y persistencia Parquet. Los modelos consumen la Zona Plata y sus salidas se publican en Oro para el dashboard.




Figura 2: Flujo de extremo a extremo del sistema.

3.2. Datasets y variables derivadas

Cuadro 3: Datasets principales por zona

Dataset	Filas	Propósito
precios_spark	34,969	Precios limpios con trazabilidad y atributos geográficos.
precios_clima_parquet	5,225	Integración semanal de precios y clima.
matriz_aprendizaje_forecasting	4,697	Rezagos, medias móviles, clima, sentimiento y targets.
tweets_sentimiento	5,132	Texto limpio, score y clase POS/NEU/NEG.
tweets_sentimiento_semanal	465	Conteos y métricas semanales de percepción social.
kpi_precios	3,132	Precio, variación y estado por producto-año-semana.
kpi_sentimiento	465	Sentimiento y porcentaje negativo por semana.
clusters_productos	6	Perfiles históricos y asignación KMeans.
alerta_binaria_productos	599	Alerta real, predicción y probabilidad en prueba.

Se generaron rezagos de una, dos y cuatro semanas, medias móviles de cuatro y ocho semanas, volatilidad móvil, variación semanal, mes, trimestre y objetivos a dos semanas. La partición de entrenamiento y prueba fue cronológica para disminuir el riesgo de fuga de información futura.

4. Fase 4: modelado y registro en MLflow

4.1. Modelo 1: forecasting a dos semanas

Después de filtrar productos agrícolas, quedaron 2,808 filas: 1,884 para entrenamiento (2017–2022) y 924 para prueba (2023–2025). La Regresión Lineal obtuvo el menor error y el mayor R^2 .

Cuadro 4: Bitácora completa del Modelo 1 incluida en el dashboard

Ejecución	RMSE	MAE	R^2
LR_Baseline	1.0169	0.3472	0.8591
RF_RandomizedSearch (1)	1.2526	0.4108	0.7862
RF_RandomizedSearch (2)	1.2471	0.3982	0.7881
XGB_RandomizedSearch	1.2363	0.3962	0.7918




Figura 3: RMSE de las ejecuciones del Modelo 1 registradas en el dashboard.

El MAE del modelo seleccionado equivale a un error absoluto medio cercano a S/ 0.35 por kilogramo. El resultado muestra que, para el conjunto analizado, la estructura lineal generaliza mejor que los modelos de árboles frente a los shocks extremos y al número reducido de productos.

4.2. Modelo 2: clustering por precio y volatilidad

KMeans con $K = 2$ obtuvo Silhouette de 0.536. Cinco productos se agruparon en el cluster 0 y el Ajo Criollo o Napurí quedó solo en el cluster 1, con precio histórico promedio de S/ 5.43 y volatilidad de 3.171. Su máximo histórico fue S/ 33.46 por kg en 2024-S32.




Figura 4: Segmentación reconstruida con los datos embebidos en el dashboard.

Cuadro 5: Detalle de los seis productos en clusters_productos

Producto	Cluster	Media S/	Volatilidad	Máximo S/
Ajo Criollo o Napurí	1	5.430	3.171	33.464
Papa Amarilla	0	2.233	0.824	5.916
Plátano Bellaco	0	1.751	0.265	2.691
Papaya	0	1.634	0.349	3.091
Camote Morado	0	1.298	0.497	4.061
Zanahoria	0	0.791	0.296	1.841

4.3. Modelo 3: clasificación de subidas superiores al 10 %

La matriz original contiene 742 alertas de 4,697 filas (15.80 %). Tras excluir productos no agrícolas se utilizaron 2,341 observaciones: 1,742 de entrenamiento y 599 de prueba. La comparación optimizada fue:

Cuadro 6: Resultados finales del notebook de clasificación

Algoritmo	AUC-ROC	F1-Score
GBT optimizado	0.6821	0.6720
Random Forest optimizado	0.6756	0.7135
Regresión Logística	0.6324	0.5811

GBT fue seleccionado por el mayor AUC-ROC, adecuado para ordenar semanas de riesgo a través de distintos umbrales. La validación cruzada obtuvo AUC promedio de 0.7122. Random Forest presenta el mayor F1 y sería una alternativa si se prioriza el equilibrio en un umbral fijo.




Figura 5: Ejecuciones de clasificación mostradas en la vista de salud del dashboard.

La vista de salud del HTML contiene una instantánea anterior: GBTCClassifier con AUC 0.6707 y F1 0.6883, RF_Corregido_Depth6 con 0.6651 y 0.6628 y Regresión Logística con 0.6324 y 0.5811. El notebook final registra una optimización posterior. Por ello, el resultado analítico final es 0.6821/0.6720, mientras que la interfaz debe sincronizarse con el run optimizado antes de un despliegue definitivo.

5. Fase 5: evaluación y resultados del dashboard

5.1. Vista 1: alertas y estado histórico

La Zona Oro aplica tres estados a las subidas semanales: NORMAL para variaciones menores a 5 %, ATENCIÓN entre 5 % y menos de 10 %, y ALERTA desde 10 %. Las caídas se conservan como NORMAL porque el objetivo operativo es detectar aumentos.




Figura 6: Distribución de los 3,132 KPI históricos de precios.

En toda la serie se observaron 2,343 registros NORMAL (74.81 %), 332 en ATENCIÓN (10.60 %) y 457 en ALERTA (14.59 %). La frecuencia de ALERTA varía por producto: Zanahoria 24.57 %, Papa Amarilla 17.47 %, Papaya 16.60 %, Ajo 16.51 %, Camote 11.32 % y Plátano Bellaco 1.15 %. Esta tasa es descriptiva y depende del precio base de cada producto; no debe confundirse con la volatilidad absoluta del clustering.




Figura 7: Proporción histórica de semanas en estado ALERTA por producto.

5.2. Vistas 1 y 2: último corte y ranking de precios

El último corte embebido en el dashboard corresponde a 2025-S52. No hubo productos en ALERTA, uno quedó en ATENCIÓN y cinco en NORMAL.

Cuadro 7: Resultados del último corte 2025-S52

Producto	Precio S/ kg	Variación	Estado
Ajo Criollo o Napurí	4.4857	0.83 %	NORMAL
Papa Amarilla	2.8071	-1.75 %	NORMAL
Plátano Bellaco	2.2500	-3.25 %	NORMAL
Camote Morado	2.2371	5.95 %	ATENCIÓN
Papaya	2.0000	-0.14 %	NORMAL
Zanahoria	1.1314	-0.75 %	NORMAL




Figura 8: Ranking por kilogramo del último corte disponible.

El Ajo Criollo o Napurí fue el producto más caro del corte, seguido por Papa Amarilla. El Camote Morado ocupó el cuarto lugar en precio, pero fue el único que requirió vigilancia por su incremento semanal.

5.3. Vistas 3 y 4: perfiles e histórico de precios

La segmentación confirma que la volatilidad no depende únicamente del precio del último corte, sino del comportamiento completo de 2015–2025. La serie histórica muestra el shock del Ajo en 2024-S32 y niveles mucho más acotados en los otros cinco productos.




Figura 9: Evolución semanal reconstruida desde los 3,132 registros de `kpi_precios`.

Los máximos observados fueron S/ 33.464 para Ajo (2024-S32), S/ 5.916 para Papa Amarilla (2022-S50), S/ 4.061 para Camote (2025-S29), S/ 3.091 para Papaya (2018-S02), S/ 2.691 para Plátano Bellaco (2025-S33) y S/ 1.841 para Zanahoria (2023-S47). Estos extremos explican parte de la separación del Ajo, aunque el clustering utiliza también el promedio y la dispersión completa.

5.4. Vista 5: sentimiento en redes sociales

El dashboard contiene 465 semanas entre 2015 y 2024. Para mejorar la legibilidad en el reporte impreso, la visualización se divide aquí en dos gráficos separados, manteniendo los mismos datos del dashboard. La semana con mayor volumen fue 2022-S14, con 104 tweets, sentimiento promedio -0.8269 y 82.69 % de mensajes negativos. El último registro social es 2024-S26: cuatro tweets, sentimiento -0.75 y 75 % negativos; por el bajo volumen, debe interpretarse con cautela.




Figura 10: Vista 5 dividida en dos gráficos: sentimiento promedio y porcentaje de tweets negativos por semana.

La visualización permite detectar semanas de deterioro en la conversación social, pero el proyecto no demuestra causalidad ni una ventaja predictiva aislada del sentimiento. Su función es complementar las variables históricas y climáticas dentro de la matriz.

5.5. Vista 6: salud del sistema y consistencia de resultados

La vista de salud muestra el modelo seleccionado, las métricas fijas y la bitácora de runs. Para Modelo 1 existe consistencia entre el notebook y el dashboard. Para Modelo 3 se identificó una diferencia de versiones entre el run mostrado y el run optimizado; esta observación es importante para la auditoría, porque la interfaz debe indicar la misma versión de modelo que produjo los scores de Oro.

Cuadro 8: Resumen de las seis vistas y su decisión asociada

N.	Vista	Resultado principal	Fuente
1	Alertas en tiempo real	0 ALERTA, 1 ATENCIÓN y 5 NORMAL en 2025-S52.	kpi_precios
2	Ranking de precios	Ajo fue el mayor precio del último corte: S/ 4.49 por kg.	kpi_precios
3	Segmentación	KMeans $K = 2$; Ajo forma el cluster de mayor volatilidad.	clusters_productos
4	Histórico	Cobertura 2015–2025 y shock máximo del Ajo en 2024-S32.	kpi_precios
5	Sentimiento	465 semanas; 43.63 % negativo ponderado.	kpi_sentimiento
6	Salud	LR_Baseline seleccionado; auditoría de runs y métricas.	MLflow / JSON embe-bido

6. Fase 6: despliegue, prueba y operación

6.1. Implementación de la capa de consumo

La demostración principal se ejecutó en Streamlit en `localhost:8501`. El HTML entregado contiene los mismos datasets, métricas y seis vistas en una versión autocontenida. Por tanto, el video y el HTML representan el mismo producto analítico, aunque no son la misma implementación técnica: Streamlit es la aplicación interactiva y el HTML es una réplica portable.

El equipo probó la recarga con datos nuevos y verificó que el tablero mostrara el nuevo corte. Esta prueba confirma la conexión funcional entre las salidas y la interfaz, pero no se registró una medición de latencia de extremo a extremo. La vista 1 puede refrescarse cada cinco minutos; sin embargo, la llegada de datos sigue siendo batch porque no se implementó un tópico Kafka o Pub/Sub activo.

6.2. Operación, reproducibilidad y seguridad

Cuadro 9: Controles operativos recomendados

Control	Validación	Momento
Disponibilidad de fuentes	Archivo esperado, fecha máxima y conteo.	Cada carga
Calidad de esquema	Columnas, tipos, nulos, duplicados y rangos.	Cada job
Integridad de Oro	Conteos, unicidad de claves y lectura Parquet.	Cada publicación
Calidad de modelos	RMSE, AUC, F1 y distribución de scores.	Reentrenamiento
Salud del dashboard	Último corte, rutas y respuesta de las seis vistas.	Cada despliegue
Sincronización ML-flow	Run activo de interfaz igual al modelo de scores.	Cada versión

Los notebooks, las rutas de GCS y los respaldos de MLflow permiten reconstruir los experimentos. Las credenciales deben excluirse del repositorio y gestionarse mediante autenticación de Google Cloud y permisos mínimos. Para producción se requiere automatizar jobs, versionar datos y modelos y conservar contratos de esquema estables en Oro.

7. Evaluación integral, impacto y limitaciones

7.1. Respuesta a las preguntas del proyecto

Cuadro 10: Preguntas analíticas y respuesta obtenida

N.	Pregunta	Resultado
1	Precisión a dos semanas	RMSE 1.0169, MAE 0.3472 y $R^2 = 0.8591$ con Regresión Lineal.
2	Mejor algoritmo de forecasting	LR_Baseline superó dos runs de Random Forest y XGBoost.
3	Perfiles de volatilidad	Dos clusters con Silhouette 0.536.
4	Producto más volátil	Ajo Criollo o Napurí: volatilidad 3.171 y máximo S/ 33.464.
5	Frecuencia de alertas futuras	742 de 4,697 observaciones (15.80 %).
6	Mejor clasificador	GBT optimizado por AUC 0.6821; RF optimizado obtuvo F1 0.7135.
7	Sentimiento social	47.9 % neutro, 43.6 % negativo y 8.5 % positivo.
8	Calidad de la matriz	4,697 filas y ausencia de nulos críticos después de la preparación.

N.	Pregunta	Resultado
9	Disponibilidad para consumo	Oro contiene KPI, clusters, scores y artefactos serializados.
10	Actualización	Se probó un nuevo corte; no se midió latencia ni se implementó streaming real.

7.2. Impacto potencial

El sistema puede reducir el tiempo entre la aparición de señales y su revisión. El forecast anticipa tendencias, el clustering prioriza productos de comportamiento inestable y la clasificación ordena semanas por riesgo. En un uso institucional, estas salidas podrían apoyar boletines preventivos, seguimiento de mercados y revisión de factores climáticos antes de que las variaciones se consoliden en reportes mensuales.

El sistema no sustituye las estadísticas oficiales ni recomienda intervenciones automáticas. Para uso público deben incorporarse volúmenes de abastecimiento, más mercados y productos, variables de importación y una calibración de umbrales con especialistas de MIDAGRI.

7.3. Limitaciones

- El análisis final se restringe a seis productos agrícolas y al mercado mayorista de Lima.
- La asignación climática se realiza mediante regiones de origen y no representa todas las rutas de abastecimiento.
- Los tweets no constituyen una muestra representativa de consumidores y su volumen varía ampliamente entre semanas.
- La capacidad discriminante del clasificador es moderada; debe usarse como priorizador, no como decisión automática.
- No se realizó una validación formal con un experto externo ni una evaluación económica de falsos positivos y falsos negativos.
- El refresco de la interfaz no equivale a ingesta en streaming; el pipeline de origen continúa en batch.
- La vista de salud debe sincronizar el run optimizado del Modelo 3 con los scores publicados.

8. Conclusiones y recomendaciones

1. Se construyó un Data Lake Medallion funcional que integra precios, clima y texto social mediante Spark y almacenamiento Parquet en GCS.
2. La Regresión Lineal fue el mejor modelo de forecasting con $R^2 = 0.8591$ y MAE de S/ 0.3472 por kg.
3. KMeans con $K = 2$ produjo una segmentación interpretable; el Ajo Criollo o Napurí requiere vigilancia diferenciada por su elevada volatilidad.
4. GBT optimizado obtuvo el mayor AUC para alertas de subida superior al 10 %, mientras Random Forest alcanzó el mayor F1. La selección depende del costo operativo de cada error.
5. La Zona Oro y las seis vistas convierten los resultados en información accionable. En 2025-S52 el Camote Morado fue el único producto en ATENCIÓN.
6. El reporte incorporó todos los resultados cuantitativos contenidos en el HTML: series de precios, ranking, alertas, clusters, sentimiento y runs de salud; los gráficos fueron reconstruidos desde los datos y no desde capturas.
7. La siguiente etapa debe automatizar la ingesta, implementar Pub/Sub o Kafka, medir latencia, ampliar cobertura y sincronizar la versión de MLflow mostrada en el dashboard.

Referencias y artefactos técnicos

1. Guevara Ponce, V. *Proyecto Final – Sistema Integral de Big Data Analytics: Solución a Problemas Reales del Perú*. Documento del curso.
2. MIDAGRI. Sistema de Abastecimiento y Precios (SISAP). <https://sistemas.midagri.gob.pe/sisap>
3. SENAMHI. Descarga de datos hidrometeorológicos. <https://www.senamhi.gob.pe/?p=descarga-datos-hidrometeorologicos>
4. X Developer Platform. <https://developer.twitter.com>
5. Apache Spark. <https://spark.apache.org>
6. MLflow. <https://mlflow.org>
7. Streamlit. <https://streamlit.io>
8. Repositorio del proyecto. <https://github.com/AlKstudent/food-price-forecasting-peru>

Archivos técnicos usados:

- 01_EDA_Exploratorio.ipynb, 02_ETL_Bronce_a_Plata.ipynb, 03_NLP_tweets_sentimiento.ipynb.
- 04_Modelo_1_Forecasting.ipynb, 05_modelo2_clustering.ipynb, 06_modelo3_clasificacion_binaria.ipynb.
- 07_zona_oro.ipynb, respaldos de MLflow, dashboard final HTML y evidencia de la aplicación Streamlit.